

Implementación de GLOBALFIT para la detección y eliminación de EGC

Informe de proyecto

Integrantes: Millaray Díaz Araujo
Benjamín Mitchell García
Profesor: Vicente Acuña
Alejando Maass
Sebastián Mendoza
Fecha de realización: 22 de junio de 2025
Fecha de entrega: 22 de junio de 2025
Santiago de Chile

Índice de Contenidos

1. Introducción	1
1.1. Objetivo	1
1.2. El problema	1
2. Metodología	2
2.1. Preparación	2
2.2. Implementación	2
2.3. Validación	3
3. Resultados	4
4. Conclusiones	6
5. Relevancia	7

1. Introducción

1.1. Objetivo

El objetivo del proyecto es implementar el algoritmo presentado en el paper leído, GLOBALFIT modificado, en *Python*, con la finalidad de identificar y eliminar ciclos generadores de energía erróneos (EGCs) en los distintos modelos metabólicos.

1.2. El problema

Los modelos metabólicos a escala genómica se han posicionado como herramientas fundamentales en la biología de sistemas. Estos permiten predecir el comportamiento fenotípico de organismos bajo distintas condiciones ambientales y genéticas, a través de simulaciones como el análisis de balance de flujo (FBA). Gracias a la capacidad para integrar información genómica, este enfoque es muy utilizado en cuanto al diseño de estrategias de ingeniería metabólica, estudios de evolución adaptativa y en la caracterización de microorganismos.

No obstante, diferentes trabajos a lo largo del tiempo han evidenciado problemas estructurales en los modelos, en particular, en aquellos generados automáticamente. Una de las principales problemáticas es la presencia de ciclos generadores de energía erróneos (*Energy-Generating Cycles*, EGCs). Estos permiten que el modelo pueda producir energía, como ATP o NADH, sin consumir nutrientes del medio. La existencia de este tipo de ciclos es termodinámicamente imposible y puede sesgar fuertemente los resultados de las simulaciones, afectando las predicciones de crecimiento de biomasa o la optimización de rutas metabólicas.

En el artículo “*Erroneous energy-generating cycles in published genome-scale metabolic networks: Identification and removal*” (Fritzemeier et al., 2017) se aborda este problema mediante la identificación sistemática de EGCs en los modelos disponibles en distintas bases de datos y propone un enfoque computacional, basado en programación lineal entera mixta y modificando el algoritmo GLOBALFIT. Este método permite eliminar los EGCs de forma automática, modificando el menor número de reacciones posibles en el modelo y asegurando al mismo tiempo que el organismo pueda seguir creciendo *in silico* bajo condiciones adecuadas.

Para este proyecto, implementaremos desde cero una versión funcional del algoritmo GLOBALFIT modificado en *Python*, utilizando como caso de prueba el modelo curado de *E. coli* *iJO1366*, mencionado en el paper, para luego evaluar el desempeño en otros modelos que contengan EGC. Esta implementación busca tanto validar la efectividad del enfoque como explorar su generalización a otros marcos computacionales y bases de datos metabólicas.

2. Metodología

2.1. Preparación

Antes de empezar, descargaremos e instalaremos todo lo necesario para poder trabajar los modelos en *Python*. Utilizaremos '*COBRApy*', el cual es un paquete que nos permite trabajar con modelos basados en restricciones para redes metabólicas. Por otro lado, desde BiGG, descargamos el modelo 'iJO1366', de *E. coli*, mencionado en el paper. Se dice que este contenía EGCs, pero fue curado manualmente, eliminando seis reacciones. Con esto ya listo, podemos ir al entorno de ejecución.

En *Python*, cargamos la librería de '*COBRApy*' y el modelo de *E. Coli* mencionado. Como este modelo está curado, si bloqueamos la entrada de nutrientes, el flujo resultante será 0, lo cual está correcto, pero para efectos del modelo de prueba, necesitamos que existan EGCs. Para esto reactivamos las reacciones '*SPODM*', '*SPODMpp*', '*SUCASPTpp*', '*SUCFUMtpp*', '*SUCMALtpp*', '*SUCTARTtpp*', que en el paper se mencionaron como eliminadas. Si ahora vemos el flujo bloqueando la entrada de nutrientes, observaremos que existe flujo positivo, indicando que existe al menos un EGC.

2.2. Implementación

La implementación del algoritmo GLOBALFIT modificado viene de la mano con el problema de optimización bi-nivel propuesto en el paper.

$$\begin{aligned}
 (PB) \quad & \min_{\delta} \left(\sum_{y \in M} (\delta_y^{RF} + \delta_y^{RB}) \right) \\
 \text{sujeto a:} \quad & S_g \times v^g = 0 \\
 & v_y^{min} \times (1 - \delta_y^{RB}) \leq v_y^g \leq v_y^{max} \times (1 - \delta_y^{RF}) \quad \forall y \in M \\
 & v_{Bio}^g \geq T_g \\
 & S_{ng} \times v^{ng} = 0 \\
 & v_y^{min} \times (1 - \delta_y^{RB}) \leq v_y^{ng} \leq v_y^{max} \times (1 - \delta_y^{RF}) \quad \forall y \in M \\
 & \min_{v^{ng}} (c^t \times v^{ng}) = 0
 \end{aligned}$$

Vamos a tratar de simplificar el problema a uno de optimización simple, usando dualidad para el problema de segundo nivel. Una vez que se tiene el problema simple, lo implementamos en *Python*,

2.3. Validación

Una vez validada la implementación sobre el modelo de *E. coli*, la idea es extender la metodología a otros modelos provenientes de otras bases de datos, de preferencia modelos generados automáticamente, como en ModelSEED, con el fin de evaluar la generalización del algoritmo y su desempeño en redes metabólicas de mayor complejidad o menor curación manual.

3. Resultados

Vamos a ver cómo transformar el problema de optimización bi-nivel a uno de optimización simple (un solo nivel). Primero, observamos cómo es el nivel inferior del problema. Este corresponde a:

$$\begin{aligned}
 (SC) \quad & \min_{v^{ng}} (v_{ATP}) \\
 & \text{sujeto a:} \\
 & S_{ng} \times v^{ng} = 0 \\
 & v_y^{min} \times (1 - \delta_y^{RB}) \leq v_y^{ng} \leq v_y^{max} \times (1 - \delta_y^{RF}), \forall y \in M
 \end{aligned}$$

Notemos que la segunda restricción, en nuestro caso, basta con acotarla por arriba, ya que se establecen todas las reacciones como irreversibles, por lo que $0 \leq v_{ng}$

Con esto en cuenta, podemos reescribir el problema (SC) como:

$$\begin{aligned}
 (SC) \quad & \min_{v^{ng}} (v_{ATP}) \\
 & \text{sujeto a:} \\
 & S_{ng} \times v^{ng} = 0 \\
 & v_y^{ng} \leq v_y^{max} \times (1 - \delta_y^{RF}), \forall y \in M
 \end{aligned}$$

Este es un problema convexo. Luego, sus condiciones **KKT** serán λ para la igualdad y μ para la desigualdad, con todos los multiplicadores mayores o iguales a cero. Calculamos el Lagrangeano asociado al problema:

$$\begin{aligned}
 L(v^{ng}, \lambda, \mu) &= (v_{ATP}) + \lambda(S_{ng}v^{ng}) + \mu(v_y^{ng} - v_y^{max}(1 - \delta_y^{RF})) \\
 \nabla L(v^{ng}, \lambda, \mu) &= c + \lambda S_{ng} + \mu
 \end{aligned}$$

con c , el vector de ceros en todas su coordenadas y uno en la coordenada del ATP. Por complementariedad y considerando la relación de las variables μ y δ tendremos que:

$$\begin{aligned}
 \mu(v_y^{ng} - v_y^{max}(1 - \delta_y^{RF})) &= 0 \\
 \mu_j &\leq 1 - \delta_j
 \end{aligned}$$

Finalmente, reemplazando en nuestro problema bi-nivel (PB), resulta el siguiente problema de optimización:

$$(PL) \quad \min_{\delta} \left(\sum_{y \in M} \delta_y^{RF} \right)$$

sujeto a:

(Crecimiento)

$$S_g v^g = 0$$

$$v_y^g \leq v_y^{max} (1 - \delta_y^{RF}) \quad \forall y \in M$$

$$v_{Bio}^g \geq T_g$$

(Restricción primal)

$$S_{ng} v^{ng} = 0$$

$$v_y^{min} \leq v_y^{max} (1 - \delta_y^{RF}) \quad \forall y \in M$$

(Gradiente Lagrangiano)

$$c + \lambda S_{ng} + \mu = 0$$

(Complementariedad)

$$\sum_j \mu_j = v_{ATP}$$

$$v_{ATP} = 0$$

$$\mu(v_y^{ng} - v_y^{max} (1 - \delta_y^{RF})) = 0$$

$$\mu_j \leq 1 - \delta_j$$

$$\mu \geq 0$$

$$\lambda \geq 0$$

Ahora que tenemos el problema adaptado a un problema de optimización simple, implementaremos en *Python* el algoritmo GLOBALFIT modificado.

4. Conclusiones

5. Relevancia

La implementación del algoritmo GLOBALFIT modificado en Python representa un aporte significativo tanto desde el punto de vista computacional como metodológico. Mientras que el algoritmo original fue desarrollado en entornos específicos y con herramientas cerradas, esta versión buscamos "democratizar" su uso mediante tecnologías abiertas como COBRApy y solvers como GLPK o HiGHS. Esto permite no solo reproducir los resultados del artículo original, sino también extender el algoritmo a distintos modelos metabólicos y bases de datos, facilitando su aplicación en contextos de investigación más amplios.

Además, este trabajo refuerza la importancia de garantizar la coherencia de la termodinámica en modelos metabólicos. Al detectar y eliminar ciclos generadores de energía erróneos (EGCs), se mejora la calidad de las predicciones hechas por los modelos, lo que es crucial para aplicaciones como el diseño de cepas en biotecnología, simulaciones evolutivas, y optimización de redes metabólicas.

Sin embargo, la implementación presenta ciertas limitaciones. Por un lado, la reformulación del problema como un MILP con una red duplicada (para verificar viabilidad y eliminar EGCs simultáneamente) puede escalar mal en modelos de gran tamaño. Por otro lado, el uso de solvers genéricos puede afectar la eficiencia en comparación con versiones optimizadas en software especializado. Además, la estrategia actual depende de la correcta identificación de las reacciones candidatas a ser restringidas, lo que puede ser sensible a la calidad de anotación del modelo.

Entre los desafíos pendientes se encuentra la generalización del algoritmo a modelos con múltiples compartimentos, el análisis automático de cuáles reacciones deben reactivarse para forzar un EGC en modelos curados, y la integración del algoritmo en pipelines de reconstrucción automática. También sería interesante explorar extensiones que combinen restricciones termodinámicas explícitas (como las usadas en TMFA) con la lógica de GLOBALFIT.